

E-Ticaret Müşteri Davranışı ve Satış Analizi Proje Raporu

Esma Sultan Acerbaş

1306240105

1. Problem Tanımı

Günümüzün rekabetçi e-ticaret ekosisteminde, şirketlerin sürdürülebilir büyüme sağlayabilmeleri için müşteri kitlelerini doğru tanıması ve satış dinamiklerini veriye dayalı olarak yönetmesi gerekmektedir.

Bu projenin temel amacı, uluslararası satış yapan bir e-ticaret şirketinin geçmiş işlem verilerini analiz ederek üç temel iş problemine çözüm üretmektir:

- Pazar ve Zaman Dinamikleri:** Satışların coğrafi dağılımı ve zaman içindeki mevsimsel trendleri nelerdir?
- Müşteri Segmentasyonu:** Müşteriler, satın alma alışkanlıklarına (RFM) göre nasıl anlamlı gruplara ayrılabilir ve bu gruplara özel hangi pazarlama stratejileri geliştirilebilir?
- Ürün Birlikteliği (Sepet Analizi):** Müşterilerin sepetlerinde en sık birlikte yer alan ürünler hangileridir ve bu durum çapraz satış fırsatlarına nasıl dönüştürülebilir?

2. Kullanılan Veri Seti ve Kaynağı

Projede, veri bilimi literatüründe yaygın olarak kullanılan ve Kaggle üzerinden erişilen "**UCI Online Retail Dataset**" kullanılmıştır.


- Veri Kaynağı:** UCI Machine Learning Repository / Kaggle
- Kapsam:** Aralık 2010 ile Aralık 2011 tarihleri arasında gerçekleşen ~541.000 adet işlem kaydı.
- Özellikler:** Veri seti, 38 farklı ülkeden müşterilere ait InvoiceNo (Fatura No), StockCode (Ürün Kodu), Description (Ürün Tanımı), Quantity (Miktar), InvoiceDate (Tarih), UnitPrice (Birim Fiyat) ve CustomerID (Müşteri ID) gibi temel e-ticaret değişkenlerini içermektedir.

3. Yöntem

Çalışma, modern veri bilimi iş akışına uygun şekilde dört temel aşamada gerçekleştirilmiştir:

- **Veri Temizleme:** 'C' önekiyle başlayan iptal/iade işlemleri, miktar veya fiyatı sıfır ve sıfırın altında olan hatalı kayıtlar ile CustomerID'si eksik olan satırlar segmentasyonu bozmamak adına veri setinden çıkarılmıştır.
- **Özellik Mühendisliği (Feature Engineering):** Tarih sütunundan yıl, ay, haftanın günü ve saat gibi zamansal özellikler türetilmiştir. Miktar ve Fiyat çarpılarak TotalPrice (Ciro) sütunu oluşturulmuştur. Ayrıca aykırı değerler analizleri saptırmaması için IQR (Interquartile Range) yöntemiyle baskılanmıştır.
- **Müşteri Segmentasyonu (Modelleme):** Her müşteri için Recency (Yenilik), Frequency (Sıklık) ve Monetary (Parasal Değer) metrikleri hesaplanmıştır.

Sağa çarpık dağılımı düzeltmek için Logaritmik Dönüşüm uygulanmış, ardından veriler StandardScaler ile ölçeklendirilmiştir. Dirsek (Elbow) yöntemiyle optimum küme sayısı k=4 olarak belirlenmiş ve **K-Means Kümeleme** algoritması kullanılmıştır.




- **Birliktelik Analizi:** Aynı fatura numarasına sahip ürünler itertools kütüphanesi yardımıyla kombinasyonlara ayrılmış ve frekans tabanlı sepet analizi gerçekleştirilmiştir.



4. Bulgular

4.1. Ülke ve Zaman Bazlı Satış Örüntüleri (S1)

Ciro dağılımı incelendiğinde Birleşik Krallık'ın (UK) satışlarda ezici bir üstünlüğe sahip olduğu görülmüştür. UK dışındaki pazarlara bakıldığında ise sırasıyla Almanya, EIRE (İrlanda) ve Fransa öne çıkmaktadır. Zaman serisi analizinde, satışların özellikle Eylül ayından itibaren yükselişe geçtiği ve Kasım ayında (Black Friday / Yılbaşı dönemi etkisiyle) zirve yaptığı gözlemlenmiştir.




Sipariş yoğunluğunun haftanın günlerine ve saatlere göre dağılımı incelendiğinde, siparişlerin büyük çoğunluğunun hafta içi günlerde ve **10:00 - 15:00** saatleri arasında gerçekleştiği tespit edilmiştir. Bu durum, şirketin müşteri tabanının B2B (işletmeden işletmeye) ağırlıklı bir profile sahip olduğunu düşündürmektedir.



4.2. Müşteri Segmentasyonu (S2)


K-Means modellemesi sonucunda müşteri tabanı, e-ticaret dinamiklerine uygun 4 anlamlı segmente ayrılmıştır:

- **High-Value (Yüksek Değerli):** Alışveriş sıklığı ve harcaması en yüksek olan VIP gruptur.
- **Loyal (Sadık):** Düzenli sipariş veren, ortalama üstü harcama yapan bağlı kitledir.
- **At-Risk (Risk Altındaki):** Geçmişte iyi harcama yapmış ancak uzun süredir siteye uğramayan müşterilerdir.
- **Dormant (Kayıp/Uyuyan):** Hem harcaması çok düşük hem de son alışveriş tarihi çok eski olan gruptur.



4.3. Birlikte Satın Alma Analizi (S3)

Aynı faturada yer alan ürünlerin frekans tabanlı analizi, belirli ürün çiftlerinin yüksek oranda birlikte satın alındığını ortaya koymuştur. Bu bulgu, e-ticaret arayüzünde "Bunu alanlar bunu da aldı" modülünün çalıştırılması ve avantajlı ürün paketleri (bundle) oluşturulması için güçlü bir temel sağlamaktadır.



5. Sınırlamalar

- **Eksik Zaman Verisi:** Veri setinde Aralık 2011 ayına ait sadece ilk 9 günün verisi bulunmaktadır. Zaman serisi analizlerinde yanıltıcı bir düşüş grafiği oluşmaması adına Aralık 2011 dönemi line chart analizinden filtre edilerek dışarıda bırakılmıştır.
- **Demografik Veri Eksikliği:** Veri setinde müşterilerin yaş, cinsiyet veya ilgi alanı gibi demografik özellikleri bulunmadığı için segmentasyon yalnızca işlem geçmişine (RFM) dayandırılmak zorunda kalmıştır.
- **Basit Birliktelik Yaklaşımı:** Sepet analizinde Apriori gibi istatistiksel algoritmalar (Support/Confidence/Lift hesaplamaları) yerine donanımsal süre kısıtlamaları sebebiyle frekans tabanlı basit sayım yöntemi tercih edilmiştir.

6. Öğrenilenler ve Sonuç

Bu proje, ham işlem verilerinden (transactional data) stratejik iş değerine uzanan uçtan uca veri bilimi sürecini deneyimlemek açısından oldukça öğretici olmuştur. Sadece kod yazmanın ötesinde, veriyi anlama ve iş problemine uyarlama konusunda şu temel kazanımlar elde edilmiştir:

- **Veri Ön İşlemenin Modeller Üzerindeki Kritik Etkisi:** Analiz öncesi yapılan temizlik adımlarının modelin kaderini belirlediği uygulamalı olarak görülmüştür. Örneğin; eksik CustomerID değerlerine sahte bir atama yapmak yerine bu satırları silmenin segmentasyonun (K-Means) doğruluğu için neden şart olduğu anlaşılmıştır.
- **Feature Engineering ve Algoritma Dinamikleri:** İşlem bazlı verilerin müşteri bazlı metrikleri olan RFM (Recency, Frequency, Monetary) formatına dönüştürülmesi projenin dönüm noktası olmuştur. K-Means gibi uzaklık tabanlı algoritmaların doğru çalışabilmesi için sağa çarpık (skewed) dağılıma sahip RFM verilerine uygulanan **Logaritmik Dönüşüm** ve **StandardScaler** adımlarının, makine öğrenmesi modelleri için "olmazsa olmaz" bir ön şart olduğu tecrübe edilmiştir.