

Online Retail Proje Prompt Günlüğü

1. Aşama: Veri Yükleme ve Proje Kurulumu

- 1- Kaggle üzerinden <https://www.kaggle.com/datasets/vijayuv/onlineretail> bu dataseti kullanarak bir veri bilimi projesi geliştireceğiz. Jupyter Lab'ta projeye başlıyoruz. pandas, numpy, matplotlib, seaborn ve sklearn kütüphanelerini import eden; Kaggle'dan indirdiğim 'Online Retail.csv' dosyasını dataframe olarak yükleyen kodu yaz

2. Aşama: Veri Temizleme ve Ön İşleme (Data Cleaning)

- 2- Online Retail veri setinde InvoiceNo sütununda 'C' ile başlayan değerler iptal edilen siparişleri gösteriyor. Ayrıca Quantity ve UnitPrice sütunlarında negatif veya sıfır değerler var. CustomerID sütununda da çok fazla null veri bulunuyor. Veri bilimi iş akışına uygun olarak; iptal siparişleri temizleyen, negatif/sıfır değerleri uçuran ve eksik CustomerID değerlerini (satırları silerek veya placeholder atayarak - hangisi mantıklıysa nedenini açıklayarak) yöneten temizleme kodunu yaz
- 3- Temizleme adımına devam ediyoruz. InvoiceDate sütununu datetime formatına çeviren ve analiz kolaylığı için YearMonth, DayOfWeek, Hour gibi yeni özellikler türeten kodu yaz. Ayrıca Quantity ve UnitPrice sütunlarındaki aşırı aykırı değerleri IQR (Interquartile Range) yöntemiyle tespit edip baskılayan veya temizleyen kodu ekle. Her adımı açıklayan yorum satırları da olsun.

3. Aşama: Keşifsel Veri Analizi (EDA) - Makro Trendler

- 4- Şimdi ilk araştırma sorumuza odaklanıyoruz. Bana şu iki grafiği yan yana veya alt alta (subplot olarak) çizecek kodu yaz:
 - Grafikte Birleşik Krallık (UK) aşırı baskın olduğu için, UK hariç tutulduğunda en yüksek toplam ciroya (TotalPrice) sahip ilk 10 ülkenin Seaborn Bar Chart (Sütun) grafiği.
 - Zaman içindeki aylık toplam ciro değişimini gösteren bir Line Chart (Çizgi) grafiği. Bu sayede mevsimselliği ve büyüme trendini görebilelim.
- 5- Aylık toplam ciro grafiğinde 2011-12 (Aralık) ayı sadece 9 günlük veri içerdiği için grafikte yanıltıcı bir düşüşe sebep oluyor. Bu ayı filtreleyerek dışarıda bırakan ve çizgi grafiğini sadece eksiksiz aylarla (Aralık 2010'dan Kasım 2011 sonuna kadar) yeniden çizen güncel kodu yaz.
- 6- İlk sorumuzun son parçası olarak; siparişlerin haftanın günlerine (DayOfWeek) ve günün saatlerine (Hour) göre nasıl yoğunlaştığını gösteren, e-ticaret operasyonlarında (reklam ve kampanya zamanlaması) doğrudan karar verisi üretebilecek bir Isı Haritası (Seaborn Heatmap) çizen kodu yaz.

4. Aşama: Özellik Mühendisliği ve Modellemeye Hazırlık (RFM)

- 7- Şimdi ikinci araştırma sorumuza (Müşteri Segmentasyonu) geçiyoruz. Modelleme öncesi veriyi müşteri seviyesine indirgemeliyiz. Veri setindeki en son tarihten 1 gün sonrasını analizin 'bugün'ü kabul ederek, her bir CustomerID için:
- Recency (Son satın almadan beri geçen gün sayısı)
 - Frequency (Toplam benzersiz fatura sayısı)
 - Monetary (Müşterinin bıraktığı toplam TotalPrice) değerlerini hesaplayan ve rfm_df adında yeni bir dataframe oluşturan kodu yaz.
- 8- K-Means uzaklık tabanlı bir algoritma olduğu için RFM verilerindeki sağa çarpıklığı (skewness) gidermeliyiz. RFM sütunlarına Log dönüşümü ($\log_{10}$) uygulayan ve ardından StandardScaler ile verileri ölçeklendiren kodu yaz. Ölçekleme öncesi ve sonrası dağılımı doğrulamak için korelasyon matrisini (Seaborn Heatmap) çizdirerek 4. zorunlu görselleştirme türümüzü de tamamlayalım.

5. Aşama: Makine Öğrenmesi Modellemesi (K-Means Segmentasyonu)

- 9- Ölçeklenmiş RFM verilerimiz üzerinde K-Means algoritması için en doğru küme (cluster) sayısını seçmek istiyorum. 1'den 10'a kadar küme sayıları için WCSS (Within-Cluster Sum of Squares) değerlerini hesaplayan ve Dirsek Yöntemi (Elbow Method) grafiğini çizen kodu yaz.
- 10- Elbow grafiğine bakarak en uygun küme sayısını seçtik. KMeans(n_clusters=4) modelini oluşturan, ölçeklenmiş veriler üzerinde eğiten ve küme etiketlerini (Cluster ID) orijinal rfm_df tablomuza ekleyen kodu yaz. Kümelerin RFM boyutlarındaki dağılımını görmek için şık Seaborn Boxplot grafikleri de ekle.
- 11- K-Means modeli çalıştı ve kümelerin RFM ortalamaları ortaya çıktı. Bana bu oluşan 4 kümeyi e-ticaret diline uygun olarak (Örn: High-Value, Loyal, At-Risk, Dormant) isimlendirerek, şirketin bu müşteri gruplarına nasıl pazarlama stratejileri uygulaması gerektiğini açıklayan, akademik bir yorum metni yaz.

6. Aşama: Gelişmiş Keşifsel Analiz (Sepet Analizi)

- 12- Son araştırma sorumuz olan S3 (Birlikte Satın Alma Analizi) aşamasına geldik. Ağır apriori kütüphanelerine boğulmadan, pandas kullanarak aynı InvoiceNo içerisinde en sık birlikte satın alınan ilk 10 ürün çiftini (Description) bulan ve bu çiftlerin birlikte kaç kez satıldığını (frekansını) bir yatay bar chart ile görselleştiren Python kodunu yaz. Bu çapraz satış (cross-sell) fırsatlarını nasıl yorumlamalıyız?